

DATA ENGINEERING PROJECT

Recruitment Marketing Data Pipeline (ETL) & Dashboard

Near Real-time Analytics | Cassandra → PySpark → MySQL → Grafana

3 min

Batch Interval

PySpark

Processing Engine

2 DBs

Data Sources

**Timer +
Queue**

Trigger Type

Docker

Infra

Project Summary

Hệ thống Data Pipeline tự động thu thập hành vi người dùng từ Apache Cassandra, xử lý và tổng hợp dữ liệu qua PySpark, sau đó nạp vào MySQL để trực quan hóa Near Real-time trên Grafana Dashboard. Giúp bộ phận kinh doanh và marketing theo dõi hiệu suất tin tuyển dụng, chiến dịch và nguồn ứng viên theo từng giờ.

Apache Cassandra | PySpark | Azure Functions | MySQL | Grafana | Docker

1. Bối Cảnh & Nhiệm Vụ

Situation — Bối Cảnh

Bộ phận kinh doanh và marketing của nền tảng tuyển dụng trực tuyến cần liên tục theo dõi hiệu suất của các tin tuyển dụng (Jobs), chiến dịch marketing (Campaigns) và nguồn cung cấp ứng viên (Publishers). Dữ liệu hành vi người dùng được ghi liên tục vào Cassandra dưới dạng log thô, chưa được làm sạch hay tổng hợp.

Task — Nhiệm Vụ

Xây dựng hệ thống Data Pipeline (ETL) tự động thu thập hành vi người dùng từ Cassandra, tổng hợp các chỉ số hiệu suất (Clicks, Conversions, Qualified/Unqualified) và nạp vào MySQL phục vụ báo cáo Near Real-time mỗi 3 phút.

2. Kiến Trúc & Luồng Dữ Liệu

Hệ thống được xây dựng trên kiến trúc Micro-batch ETL, triển khai hoàn toàn trong môi trường container hoá Docker, mô phỏng cloud Azure:



Chi tiết Luồng Xử Lý ETL (5 Giai Đoạn)

- 01** **Orchestration** — Azure Function App (Timer Trigger) kích hoạt ETL định kỳ mỗi 3 phút. Hỗ trợ cả cơ chế bất đồng bộ qua Azure Queue Storage.
- 02** **Extract (CDC)** — Đọc bảng tracking từ Cassandra. Sử dụng UDF phân giải UUIDv1 từ create_time, lọc incremental chỉ lấy bản ghi mới ($ts \geq mysql_last_updated_at$). Dừng sớm nếu không có dữ liệu mới.
- 03** **Transform** — Tách luồng Spark thành 4 nhánh song song (Clicks, Conversions, Qualified, Unqualified), Group By theo {job_id, date, hour, publisher_id, campaign_id, group_id}, tính Spend = clicks x bid_set. Full Outer Join 4 nhánh để giữ toàn bộ vết dữ liệu.
- 04** **Enrichment** — Left Join kết quả Spark với bảng job từ MySQL để bổ sung company_id. Ép kiểu, chuẩn hóa dữ liệu khớp schema bảng đích events.
- 05** **Load** — Ghi append kết quả vào MySQL qua Spark JDBC. Tự động cập nhật updated_at = MAX(ts) của lô vừa xử lý làm mốc cho lần chạy tiếp theo.

3. Cấu Trúc Dữ Liệu (Database Schema)

A. Cassandra — Bảng Nguồn (recruitment.tracking)

Lưu trữ raw tracking log từ tương tác người dùng. Các trường cột lõi phục vụ ETL:

Tên Cột	Kiểu Dữ Liệu	Mô Tả
create_time	TEXT (PK)	Thời gian tạo sự kiện dạng UUIDv1 — dùng để phân giải mốc thời gian chính xác
ts	TEXT	Timestamp tương tác dạng string '2026-06-24 10:30:00' — dùng để lọc Incremental
job_id	INT	Mã tin tuyển dụng — khóa nhóm chính trong aggregation
publisher_id	INT	Mã nguồn tuyển dụng — phân tích chất lượng kênh
campaign_id	INT	Mã chiến dịch marketing — tối ưu ngân sách
group_id	INT	Mã nhóm tin tuyển dụng
custom_track	TEXT	Loại sự kiện: click conversion qualified unqualified
bid	INT	Giá thầu (chỉ áp dụng cho sự kiện click, mặc định 0)

B. MySQL — Bảng Đích (etl_database.events)

Lưu dữ liệu tổng hợp sau ETL — là đầu vào cho Grafana Dashboard:

Tên Cột	Kiểu Dữ Liệu	Mô Tả
job_id	INT	Mã tin tuyển dụng
dates / hours	DATE / INT	Ngày và khung giờ tương tác (0-23) — phân tích theo thời gian
clicks	INT	Tổng lượt nhấp chuột trong khung giờ
bid_set	DECIMAL(10,2)	Giá thầu trung bình (Average Bid)
spend_hour	DECIMAL(10,2)	Tổng chi phí = clicks x bid_set
conversion	INT	Số hồ sơ ứng tuyển thành công
qualified_application	INT	Số hồ sơ đạt chuẩn
disqualified_application	INT	Số hồ sơ không đạt chuẩn
company_id	INT	Mã công ty (join từ bảng job)
publisher_id	INT	Mã nguồn/kênh quảng cáo
campaign_id	INT	Mã chiến dịch marketing
updated_at	TIMESTAMP	Mốc đồng bộ — MAX(ts) của lô Cassandra vừa xử lý

C. MySQL — Job Metadata (bảng `job`)

Lưu thông tin chi tiết tin tuyển dụng — dùng để Join & làm giàu dữ liệu (Data Enrichment) trong ETL:

Tên Cột	Kiểu Dữ Liệu	Mô Tả	Dữ Liệu Mẫu
id	INT (PK)	Mã định danh tin tuyển dụng	1
title	VARCHAR(255)	Tiêu đề công việc	'Python Developer'
company_id	INT	Mã công ty sở hữu tin — dùng để JOIN trong ETL	1
campaign_id	INT	Mã chiến dịch quảng cáo	10
group_id	INT	Mã nhóm tin tuyển dụng	20
budget	DECIMAL(10,2)	Ngân sách tối đa cho tin tuyển dụng	50.00
work_schedule	VARCHAR(50)	Hình thức làm việc (Full-time, Part-time...)	'FULL_TIME'
role_location	VARCHAR(50)	Hình thức làm việc (Remote, Onsite, Hybrid...)	'REMOTE'


resume_optional	VARCHAR(50)	Yêu cầu hồ sơ xin việc	'REQUIRED'
redirect_url	VARCHAR(255)	URL chuyển hướng khi ứng viên nộp đơn	'http://localhost/job/1'
status	INT	Trạng thái tin tuyển dụng	1
is_active	TINYINT	Trạng thái hoạt động (1: Active, 0: Inactive)	1
start_date	TIMESTAMP	Ngày bắt đầu tuyển dụng	NULL
end_date	TIMESTAMP	Ngày kết thúc dự kiến	NULL
close_date	TIMESTAMP	Ngày đóng tin thực tế	NULL
minor_id	INT	Mã ngành phụ	1
created_by	VARCHAR(255)	Người tạo bản ghi	'admin'
created_date	TIMESTAMP	Thời gian tạo bản ghi	2026-06-24 10:30:00
last_modified_by	VARCHAR(255)	Người cập nhật cuối cùng	'admin'
last_modified_date	TIMESTAMP	Thời gian cập nhật cuối cùng	2026-06-24 10:30:00

D. MySQL — Publisher Metadata (bảng `master\_publisher`)


Lưu thông tin các nguồn cung cấp ứng viên / kênh quảng cáo (Publishers) — dùng để phân tích chi phí và chất lượng kênh:

Tên Cột	Kiểu Dữ Liệu	Mô Tả	Dữ Liệu Mẫu
id	INT (PK)	Mã định danh Publisher	1
publisher_name	VARCHAR(255)	Tên nguồn / kênh tuyển dụng	'Facebook'
publisher_email	VARCHAR(255)	Email liên hệ của Publisher	'Facebook@mail.com'
publisher_type	INT	Loại kênh tuyển dụng	0
publisher_group	INT	Nhóm kênh tuyển dụng	1
publisher_currency	VARCHAR(50)	Đơn vị tiền tệ áp dụng giá thầu	'1'
min_bid	DECIMAL(10,2)	Giá thầu tối thiểu chấp nhận	1.00
max_bid	DECIMAL(10,2)	Giá thầu tối đa chấp nhận	1.00
cpc_increment	DECIMAL(10,2)	Mức gia tăng chi phí trên mỗi click	0.00
bid_reading_interval	INT	Chu kỳ đọc giá thầu (giờ)	1
time_zone	VARCHAR(100)	Múi giờ làm việc của Publisher	'SE Asia Standard Time'
countries	VARCHAR(255)	Quốc gia hoạt động tuyển dụng	'VN'
data_sharing	TEXT	Danh sách cấu hình chia sẻ dữ liệu doanh nghiệp	'[]'
access_token	VARCHAR(255)	Token bảo mật để gửi log tracking	'b01aba43-...'
publisher_code	INT	Mã code kênh	0
is_active	TINYINT	Trạng thái hoạt động (1: Active, 0: Inactive)	1
created_by	VARCHAR(255)	Người tạo bản ghi	'admin'
created_date	TIMESTAMP	Thời gian tạo bản ghi	2026-06-24 10:30:00
last_modified_by	VARCHAR(255)	Người cập nhật cuối cùng	'admin'
last_modified_date	TIMESTAMP	Thời gian cập nhật cuối cùng	2026-06-24 10:30:00

4. Technology Stack



5. Kết Quả & Grafana Dashboard



Grafana Dashboard — Near Real-time KPI Monitoring

Tracking hiệu suất Job
Theo dõi chính xác Clicks, Spend, Conversion của từng tin tuyển dụng theo giờ

Đánh giá chất lượng Publisher
Phân tích tỷ lệ Qualified/Unqualified từng nguồn tuyển dụng

Tối ưu ngân sách
Nắm bắt tình hình theo giờ để ra quyết định tối ưu chi phí quảng cáo

6. Hướng Dẫn Cài Đặt & Chạy Hệ Thống

Bước 1 — Cài đặt thư viện Python

```
pip install pandas mysql-connector-python cassandra-driver requests
```

Bước 2 — Khởi động Docker Compose

```
docker compose up -d --build
```

Bước 3 — Khởi tạo Schema & Seed Data

```
python src/init db.py
```

Bước 4A — Sinh dữ liệu (trực tiếp Cassandra)

```
python src/generate dummy data.py
```

Bước 4B — Sinh dữ liệu (qua HTTP API)

```
python src/generate dummy data api.py
```

Bước 5 — Theo dõi ETL logs

```
docker logs -f etl function app
```

Bước 6 — Truy cập Grafana Dashboard

```
http://localhost:3000 (admin / admin)
```